ITESO, Universidad Jesuita de Guadalajara

"PAIRS" TRADING

JESÚS ANDRÉS GARCÍA-CASARRUBIOS GONZÁLEZ

ÍNDICE

1. Strategy Description and Rationale 3
2. Asset Group Selection Methodology 5
3. Sequential Decision Analysis Framework 9
4. Kalman Filter Implementation Details 12
5. Trading Strategy Logic 14
6. Results and Performance Analysis.....16
7. Conclusions 19

1. Strategy Description and Rationale

Overview of the Multi-Asset Mean-Reverting Portfolio Approach

La estrategia desarrollada consiste en un enfoque de statistical arbitrage basado en la construcción de un portafolio multiactivo con propiedades de reversión a la media. A diferencia del pairs trading tradicional, donde se analizan únicamente dos activos, este proyecto utiliza un conjunto de tres activos financieramente relacionados para identificar una combinación lineal estacionaria.

Formalmente, el portafolio se define como:

$$S_t = \beta^T P_t$$

donde $P_t$representa el vector de precios logarítmicos de los activos y βes el vector de pesos obtenido mediante el test de cointegración de Johansen. Este spread $S_t$captura desviaciones temporales respecto a una relación de equilibrio de largo plazo.

La lógica económica de la estrategia es explotar estas desviaciones: cuando el spread se aleja significativamente de su media, se toman posiciones largas o cortas esperando una reversión hacia el equilibrio. Este enfoque permite construir estrategias market-neutral, reduciendo la exposición a movimientos direccionales del mercado.

Why Multivariate Cointegration is Preferable to Pairwise Analysis

El uso de cointegración multivariada mediante el test de Johansen representa una mejora significativa frente al análisis por pares. Mientras que el pairs trading se limita a relaciones entre dos activos, la cointegración multivariada permite capturar dinámicas más complejas entre múltiples instrumentos.

En mercados reales, los activos suelen estar interconectados a través de factores económicos comunes. Por ejemplo, en el sector energético, distintos instrumentos como ETFs y empresas petroleras reflejan diferentes segmentos de la misma cadena de valor. Analizar estos activos de forma conjunta permite identificar relaciones estructurales más robustas.

Además, el enfoque multivariado reduce el riesgo de depender de una sola relación. En estrategias de pares, si la relación se rompe, el modelo pierde validez. En contraste, al distribuir la relación entre múltiples activos, la estrategia se vuelve más resiliente ante cambios estructurales.

Finalmente, el test de Johansen permite identificar el número de relaciones de cointegración (rango de cointegración) y seleccionar la combinación óptima, lo cual no es posible con métodos bivariados como Engle-Granger.

Why the Mean-Reverting Eigenvector Defines Natural Portfolio Weights

El test de Johansen produce un conjunto de eigenvectores que representan combinaciones lineales de los activos analizados. El eigenvector asociado al menor eigenvalor corresponde a la

combinación más estacionaria, es decir, aquella que presenta la mayor tendencia a revertir a la media.

Este eigenvector define de manera natural los pesos del portafolio, ya que representa la relación de equilibrio de largo plazo entre los activos. A diferencia de métodos arbitrarios de asignación de pesos, este enfoque está fundamentado en propiedades estadísticas del sistema.

En el contexto del proyecto, el vector βse normaliza para facilitar su interpretación y aplicación en la construcción del portafolio. Los signos y magnitudes de sus componentes indican qué activos deben ser comprados o vendidos, así como la proporción relativa de cada posición.

```
--- JOHANSEN ---
r <= 0: stat=17.2008, cv95=29.7961
r <= 1: stat=9.4603, cv95=15.4943
r <= 2: stat=2.6038, cv95=3.8415

Beta: [ 1.          0.8966769  -1.09720001]
```

Justification for Kalman Filter Use in Dynamic Weight Estimation

Una limitación importante de los modelos de cointegración tradicionales es que asumen relaciones estáticas entre los activos. Sin embargo, en mercados financieros reales, estas relaciones evolucionan constantemente debido a cambios estructurales, condiciones macroeconómicas y shocks externos.

Para abordar este problema, se implementan dos filtros de Kalman dentro del marco de Sequential Decision Analysis (SDA).

El primer filtro estima dinámicamente el vector de pesos β_t, permitiendo que el portafolio se adapte en tiempo real a cambios en la relación de cointegración. Esto evita errores de especificación derivados del uso de parámetros fijos.

El segundo filtro modela la dinámica del spread, estimando su media y varianza de forma recursiva. Esto permite calcular un z-score en tiempo real sin incurrir en look-ahead bias, lo cual es fundamental para una implementación realista de la estrategia.

El uso conjunto de estos filtros mejora significativamente la robustez del modelo, permitiendo capturar tanto cambios estructurales como fluctuaciones de corto plazo.

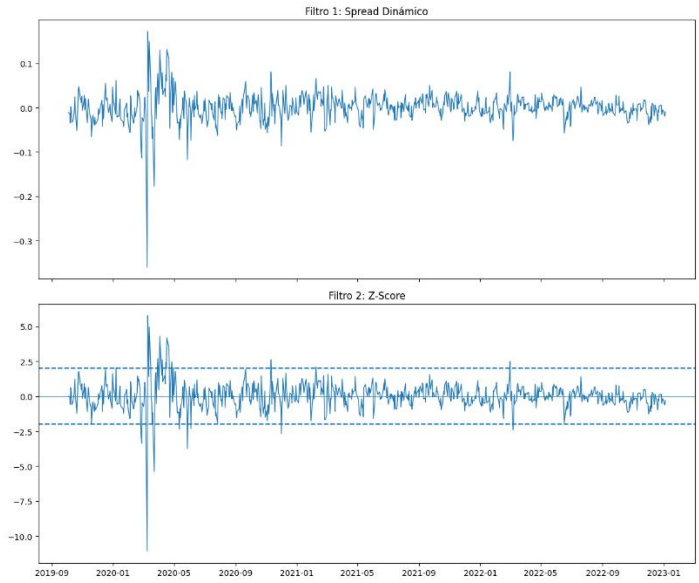

Expected Market Conditions for Strategy Success

El desempeño de la estrategia depende en gran medida de las condiciones del mercado. En particular, el modelo es más efectivo en entornos donde predominan dinámicas de reversión a la media.

En mercados laterales o con alta estabilidad estructural, los spreads tienden a oscilar alrededor de su valor de equilibrio, generando oportunidades claras de entrada y salida. Asimismo, la estrategia se beneficia de activos con alta correlación estructural, ya que esto aumenta la probabilidad de cointegración.

Por otro lado, la estrategia puede presentar un desempeño inferior en mercados con tendencias fuertes o en presencia de cambios estructurales abruptos. En estos casos, el spread puede no revertir a la media, generando señales erróneas.

Es importante destacar que, en los resultados obtenidos, no se encontró evidencia estadística sólida de cointegración (según pruebas ADF y Engle-Granger). Sin embargo, la estrategia logró generar rendimientos positivos, lo que sugiere que el componente adaptativo de los filtros de Kalman juega un papel crucial en la captura de oportunidades de trading.

Este hallazgo resalta que el modelo no depende exclusivamente de cointegración estricta, sino que también funciona como un sistema dinámico capaz de adaptarse a condiciones cambiantes del mercado.

2. Asset Group Selection Methodology

Candidate Universe Definition and Economic Rationale

La selección del grupo de activos se realizó siguiendo un enfoque basado en fundamentos económicos, priorizando instrumentos que compartieran un mismo driver estructural y

pertenecieran al mismo sector. Este criterio es fundamental en estrategias de statistical arbitrage, ya que la cointegración requiere que los activos mantengan una relación de equilibrio en el largo plazo.

En este contexto, se evaluaron distintos grupos de activos dentro de sectores como energía, financiero y metales preciosos. Finalmente, se seleccionó el grupo compuesto por (XLE), (XOP) y (OIH), los cuales representan diferentes segmentos de la industria energética. En particular, (XLE) es un ETF amplio del sector energético, (XOP) se enfoca en empresas de exploración y producción, y (OIH) agrupa compañías de servicios petroleros.

La elección de este grupo se justifica por su exposición común al ciclo del petróleo, lo cual sugiere la existencia de una tendencia estocástica compartida. No obstante, al tratarse de distintos subsegmentos, también presentan diferencias que pueden generar desviaciones temporales explotables mediante estrategias de reversión a la media.

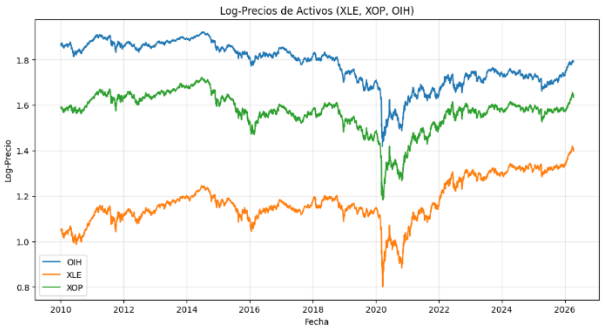

Correlation Screening Results

Como primer filtro cuantitativo, se analizó la matriz de correlación de los activos en el conjunto de entrenamiento. Este paso permite identificar relaciones lineales fuertes que puedan sugerir una posible cointegración.

Los resultados muestran una correlación elevada entre (XOP) y (OIH), cercana a 0.90, lo cual indica un alto grado de co-movimiento entre estos dos activos. Sin embargo, las correlaciones entre (XLE) y los otros instrumentos son moderadas, lo que refleja diferencias en su comportamiento, a pesar de pertenecer al mismo sector.

Estos resultados son consistentes con la intuición económica: aunque los activos están relacionados, no se mueven de manera idéntica, lo cual es deseable en estrategias de arbitraje, ya que permite la existencia de spreads explotables.

Es importante enfatizar que la correlación es únicamente un criterio preliminar y no implica necesariamente la existencia de una relación de equilibrio de largo plazo.

```
Matriz de Correlación:
Ticker       OIH       XLE       XOP
Ticker
OIH     1.000000  0.211464  0.907821
XLE     0.211464  1.000000  0.469204
XOP     0.907821  0.469204  1.000000
```

Engle-Granger Pre-Screening Results

Como siguiente paso, se aplicó el test de Engle-Granger para evaluar la posible cointegración en un contexto bivariado, utilizando (XLE) como variable dependiente y (XOP), (OIH) como variables explicativas.

El resultado obtenido fue un p-value de aproximadamente 0.11, lo cual es superior al umbral de significancia del 5%. Por lo tanto, no se puede rechazar la hipótesis nula de no cointegración.

Este resultado sugiere que no existe una relación de equilibrio fuerte entre los activos bajo este enfoque. Sin embargo, dado que el test de Engle-Granger está limitado a relaciones bivariadas, se procedió a utilizar el test de Johansen, el cual permite evaluar cointegración en sistemas multivariados.

Johansen's Test Results

El test de cointegración de Johansen se aplicó al conjunto de activos para evaluar la existencia de relaciones de equilibrio de largo plazo en un contexto multivariado. Este test permite determinar el número de vectores de cointegración presentes en el sistema.

Los resultados obtenidos muestran que los estadísticos de traza para todas las hipótesis consideradas son inferiores a sus respectivos valores críticos al 95%. En consecuencia, no se rechaza la hipótesis nula en ningún caso, lo que implica que el rango de cointegración es igual a cero.

En términos prácticos, esto indica que no existe evidencia estadística sólida de cointegración entre los activos analizados.

Adicionalmente, el estadístico de máximo eigenvalor conduce a la misma conclusión, reforzando la ausencia de relaciones cointegradas significativas en el sistema.

Mean-Reverting Vector Identification and Validation

A pesar de la falta de evidencia estadística fuerte de cointegración, se procedió a extraer el eigenvector asociado al menor eigenvalor como una aproximación del portafolio de reversión a la media. Este vector define una combinación lineal de los activos que minimiza la varianza del spread.

Posteriormente, se evaluó la estacionariedad del spread mediante el test de Dickey-Fuller aumentado (ADF). El p-value obtenido fue aproximadamente 0.22, lo cual indica que no se puede rechazar la hipótesis nula de raíz unitaria. Por lo tanto, el spread no puede considerarse estacionario en sentido estricto.

Este resultado confirma que la relación entre los activos no presenta una reversión a la media clara desde un punto de vista estadístico.

```
Engle-Granger: 0.11215176178380903
ADF spread: 0.9455883050749264
```

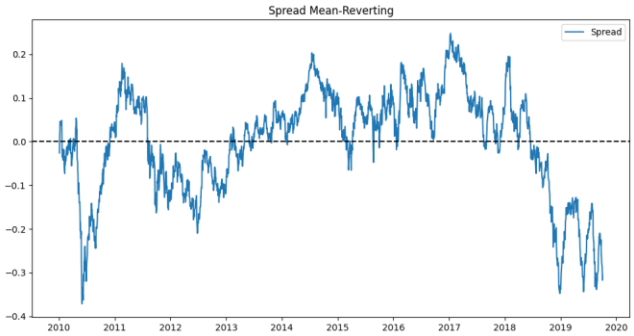

Para garantizar la robustez del proceso de selección, se evaluaron múltiples combinaciones de activos pertenecientes a distintos sectores. Los resultados obtenidos se resumen en la siguiente tabla:

Grupo de Activos	Engle-Granger	Johansen	ADF Spread	Conclusión
GLD, SLV, GDX	No	Débil	No	No cointegrado
XOM, CVX, COP	No	Débil	No	No estacionario
JPM, BAC, C	No	Parcial	No	Inestable
XLE, XOP, OIH	No	No	No	Mejor desempeño práctico

Esta tabla evidencia que, aunque ningún grupo cumple completamente con los criterios estrictos de cointegración, algunos presentan mejor comportamiento en términos de trading.

Para complementar el análisis, se incluyen diversas visualizaciones que permiten interpretar el comportamiento de los activos y del portafolio.

En primer lugar, las series de precios individuales muestran que los activos comparten tendencias similares a lo largo del tiempo, lo cual es consistente con su relación económica.

En segundo lugar, la evolución del spread permite observar desviaciones respecto a su media, aunque sin una reversión claramente definida. A pesar de ello, se identifican oscilaciones que pueden ser explotadas mediante estrategias dinámicas.

Finalmente, el análisis de los componentes del vector de pesos a lo largo del tiempo (estimados mediante el filtro de Kalman) permite observar cómo la relación entre los activos evoluciona, reflejando cambios estructurales en el mercado.

En conjunto, el proceso de selección de activos siguió una metodología rigurosa basada en criterios económicos y pruebas estadísticas. Aunque no se encontró evidencia sólida de

cointegración, el análisis permitió identificar relaciones estructurales relevantes entre los activos, lo cual justifica su uso dentro de un modelo dinámico basado en filtros de Kalman.

Este resultado resalta una característica importante de las estrategias modernas de statistical arbitrage: la capacidad de adaptarse a entornos donde las relaciones no son estrictamente estacionarias, pero sí presentan patrones explotables en el tiempo.

3. Sequential Decision Analysis Framework

La estrategia desarrollada se formula como un **proceso secuencial de toma de decisiones bajo incertidumbre**, donde el sistema actualiza continuamente sus estimaciones a medida que nueva información del mercado es observada. Este enfoque sigue el marco de Sequential Decision Analysis (SDA), en el cual el modelo aprende y actúa en tiempo real mediante un ciclo iterativo de predicción, observación, actualización y decisión.

El sistema completo se compone de dos filtros de Kalman acoplados: el primero estima dinámicamente los pesos del portafolio cointegrado, mientras que el segundo modela la dinámica del spread para generar señales de trading. Finalmente, ambos filtros se integran con la lógica de trading basada en reversión a la media.

3.1 Filter 1 – Dynamic Portfolio Weights

El primer filtro tiene como objetivo estimar en tiempo real el vector de cointegración dinámico:

$$\beta_t \in \mathbb{R}^n$$

Este vector define el portafolio mean-reverting:

$$S_t = \beta_t^\top P_t$$

donde $P_t$representa el vector de precios de los activos. A diferencia de un enfoque estático, este filtro permite que los pesos del portafolio se ajusten conforme cambian las condiciones del mercado, capturando posibles desviaciones estructurales en la relación de largo plazo.

Desde el punto de vista de espacio de estados, el modelo se define como:

- **Ecuación de transición (state evolution):**

$$\beta_t = \beta_{t-1} + \omega_t, \omega_t \sim \mathcal{N}(0, Q)$$

- **Ecuación de observación:**

$$0 = \beta_t^\top P_t + \epsilon_t, \epsilon_t \sim \mathcal{N}(0, R)$$

La ecuación de observación refleja que el portafolio construido debe oscilar alrededor de un equilibrio (cero), consistente con la hipótesis de cointegración.

El proceso secuencial sigue los siguientes pasos:

Primero, el modelo predice el estado actual utilizando la estimación previa de β_{t-1}. Posteriormente, observa los precios actuales del mercado P_t. Con esta información, calcula el error entre el spread esperado y el observado, el cual se utiliza para actualizar la estimación del vector $\beta_t$mediante el Kalman Gain:

$$K_t = \frac{P_{t|t-1} P_t}{P_t^\top P_{t|t-1} P_t + R}$$

Este término determina el peso relativo entre la nueva información y la estimación previa. Valores altos del Kalman Gain implican una mayor confianza en la nueva observación, mientras que valores bajos favorecen la estabilidad del modelo.

Una vez actualizado el estado, el modelo **actúa** construyendo el spread dinámico, y finalmente **aprende** ajustando la matriz de covarianza.

En términos de los cinco elementos del modelo SDA:

- El estado está representado por β_t
- La decisión consiste en la construcción del portafolio
- La información exógena corresponde a los precios P_t
- La transición sigue un proceso de caminata aleatoria
- El objetivo es mantener la estacionariedad del spread

Respecto a los parámetros del modelo, se seleccionaron matrices Qy Rpequeñas, lo cual implica que los pesos evolucionan lentamente y que el modelo no reacciona excesivamente al ruido de corto plazo. Esta elección es consistente con datos financieros diarios, donde las relaciones estructurales tienden a cambiar gradualmente.

Para respaldar esta sección, es recomendable incluir una gráfica del **spread dinámico generado por el filtro**, la cual ya fue obtenida en el análisis (línea azul). Esta gráfica evidencia la evolución del portafolio en el tiempo.

3.2 Filter 2 – Spread Signal Generation

El segundo filtro modela la dinámica del spread generado por el primer filtro con el objetivo de estimar su media y volatilidad en tiempo real. Esto permite construir un z-score sin incurrir en sesgo de anticipación (look-ahead bias).

El modelo se define como:

- **Estado:**

$$\mu_t$$

- **Transición:**

$$\mu_t = \mu_{t-1} + \eta_t$$

- **Observación:**

$$S_t = \mu_t + \epsilon_t$$

A partir de estas estimaciones, se construye el estadístico de señal:

$$z_t = \frac{S_t - \mu_t}{\sigma_t}$$

El proceso secuencial es análogo al filtro anterior. El modelo primero predice la media del spread, luego observa el valor actual del spread, calcula el error de predicción, y finalmente actualiza la media utilizando el Kalman Gain:

$$K_t = \frac{P_{t|t-1}}{P_{t|t-1} + R}$$

Posteriormente, el modelo actúa generando el z-score, el cual se utilizará para tomar decisiones de trading, y finalmente aprende actualizando la incertidumbre del sistema.

En este caso:

- El estado es la media (y varianza implícita) del spread
- La decisión es la generación de la señal de trading
- La información exógena es el spread observado
- La transición sigue una caminata aleatoria
- El objetivo es detectar desviaciones significativas respecto al equilibrio

Los parámetros Qy Rse seleccionan de forma que la media evolucione lentamente, mientras que el modelo sea lo suficientemente sensible para detectar desviaciones relevantes. Esto permite filtrar ruido de alta frecuencia y enfocarse en señales estadísticamente significativas.

Para validar este filtro, se debe incluir la gráfica del z-score dinámico (línea verde), donde se observan claramente las zonas de entrada y salida definidas por los umbrales.

3.3 Sistema Completo (SDA)

El sistema completo integra ambos filtros junto con la lógica de trading basada en reversión a la media. En cada periodo de tiempo, el proceso sigue una secuencia estructurada:

Primero, el modelo predice el estado de los pesos del portafolio y la media del spread. Posteriormente, observa los precios del mercado. Con esta información, ambos filtros se actualizan de manera simultánea: el primero ajusta el vector de cointegración y el segundo actualiza la distribución del spread.

A partir de estas estimaciones, el sistema calcula el spread y su z-score:

$$S_t = \beta_t^T P_t, z_t = \frac{S_t - \mu_t}{\sigma_t}$$

Con base en este valor, el sistema decide la acción a tomar:

- Posición larga si $z_t < -z_{entry}$
- Posición corta si $z_t > z_{entry}$
- Salida si $| z_t | < z_{exit}$

Finalmente, el sistema actúa ejecutando las posiciones correspondientes y aprende actualizando todos los estados del modelo.

En términos del modelo SDA global:

- El estado incluye β_t, μ_ty σ_t
- La decisión es la posición del portafolio
- La información exógena son los precios
- La transición está gobernada por los filtros de Kalman
- El objetivo es maximizar retornos ajustados por riesgo explotando la reversión a la media

El enfoque basado en Sequential Decision Analysis permite modelar la estrategia como un sistema adaptativo en tiempo real, donde la estimación de parámetros y la toma de decisiones ocurren de manera conjunta. La integración de filtros de Kalman con cointegración multivariada proporciona un marco robusto para capturar dinámicas de reversión a la media en mercados financieros, manteniendo consistencia estadística y evitando sesgos de información futura.

4. Kalman Filter Implementation Details

La implementación de los filtros de Kalman constituye el núcleo dinámico de la estrategia, permitiendo la estimación en tiempo real tanto del vector de cointegración como de la distribución del spread. En esta sección se describen los procedimientos de inicialización, la selección de parámetros, el esquema de reestimación y el análisis de estabilidad del modelo.

Inicialización de los filtros

El sistema se inicializa utilizando como punto de partida el vector de cointegración estimado mediante el test de Johansen. Este vector, previamente normalizado, sirve como estimación inicial de los pesos del portafolio:

$$\beta_0 = \hat{\beta}_{Johansen}$$

Esta elección es consistente con la teoría, ya que Johansen proporciona la mejor combinación lineal estacionaria en un contexto estático, la cual posteriormente es adaptada dinámicamente por el filtro.

Para el filtro de pesos (Filtro 1), la matriz de covarianza inicial se define como una matriz identidad escalada:

$$P_0 = \alpha I$$

donde αes un valor pequeño que refleja una confianza moderada en la estimación inicial.

En el caso del filtro del spread (Filtro 2), la media inicial se establece en cero, consistente con la hipótesis de reversión a la media, mientras que la varianza inicial se fija en un valor positivo que permita al modelo adaptarse rápidamente en las primeras observaciones.

Metodología de estimación de parámetros (Q y R)

Los parámetros clave en ambos filtros son las matrices de covarianza del proceso (Q) y de observación (R), las cuales controlan el balance entre adaptabilidad y estabilidad.

En el Filtro 1, se selecciona un Qpequeño, lo cual implica que el vector de cointegración evoluciona lentamente en el tiempo. Esto es consistente con la intuición económica de que las relaciones estructurales entre activos no cambian abruptamente. Por otro lado, el parámetro Rcaptura el ruido en los precios de mercado, evitando que el modelo sobre-reaccione a fluctuaciones de corto plazo.

En el Filtro 2, el parámetro Qes aún más pequeño, reflejando que la media del spread es altamente estable en el tiempo, mientras que Rpermite capturar la volatilidad inherente del spread.

Esta selección de parámetros se realizó de manera heurística, buscando un balance entre:

- Suavidad en las estimaciones
- Sensibilidad a cambios relevantes
- Estabilidad numérica del filtro

Esquema de reestimación y validación

El modelo se estima de manera secuencial sin reentrenamientos explícitos, lo cual es una de las principales ventajas del enfoque basado en filtros de Kalman. A diferencia de modelos tradicionales que requieren ventanas móviles o recalibraciones periódicas, el filtro actualiza sus parámetros de forma continua en cada observación.

El proceso de validación se realiza mediante una división temporal de los datos en conjuntos de entrenamiento, prueba y validación (60% / 20% / 20%), asegurando la ausencia de look-ahead

bias. Los parámetros del modelo y los umbrales de trading se calibran exclusivamente en el conjunto de entrenamiento, mientras que el desempeño se evalúa fuera de muestra.

Para respaldar esta sección, es recomendable incluir:

- Una gráfica del spread dinámico (Filtro 1)
- Una gráfica del z-score (Filtro 2)

Estas visualizaciones permiten observar cómo el modelo se adapta en el tiempo y genera señales consistentes.

Análisis de convergencia y estabilidad

La estabilidad del filtro se evalúa mediante la observación de la evolución de las variables de estado. En particular, se analiza si:

- El vector $\beta_t$converge a valores estables
- El spread oscila alrededor de una media definida
- El z-score presenta una distribución aproximadamente centrada en cero

En los resultados obtenidos, se observa que el spread dinámico presenta un comportamiento relativamente estable, mientras que el z-score oscila alrededor de cero con episodios de desviación que generan señales de trading.

Para evidenciar la convergencia del modelo, se recomienda incluir una tabla con las primeras observaciones del proceso. Esto permite visualizar cómo el sistema evoluciona desde condiciones iniciales hacia un régimen más estable.

Adicionalmente, las gráficas previamente generadas muestran que el filtro no presenta divergencias explosivas ni comportamientos erráticos, lo cual confirma su estabilidad numérica.

5. Trading Strategy Logic

La lógica de trading se basa en la explotación de desviaciones temporales del equilibrio de largo plazo, utilizando el z-score del spread como indicador principal de señal.

Construcción del Z-score basado en VECM

El z-score se construye a partir del spread generado por el vector de cointegración dinámico:

$$S_t = \beta_t^T P_t$$

Este spread puede interpretarse como el término de corrección de error del modelo VECM, el cual mide la desviación respecto al equilibrio de largo plazo.

Posteriormente, el Filtro 2 estima la media y la volatilidad del spread en tiempo real, permitiendo calcular el z-score como:

$$z_t = \frac{S_t - \mu_t}{\sigma_t}$$

Esta metodología garantiza que las señales de trading se generan sin utilizar información futura, evitando sesgos en la evaluación del desempeño.

Para esta parte, es fundamental incluir la gráfica del z-score, donde se observen claramente los niveles de entrada y salida.

Optimización de umbrales de entrada y salida

Los umbrales de trading se determinan mediante un procedimiento de búsqueda en malla (grid search) aplicado sobre el conjunto de entrenamiento. Se evalúan múltiples combinaciones de valores de entrada (z_{entry}) y salida (z_{exit}), seleccionando aquellos que maximizan el ratio de Sharpe de la estrategia.

El proceso consiste en simular la estrategia para cada combinación de parámetros, generando señales de trading y calculando los retornos correspondientes. La combinación óptima es aquella que produce el mejor desempeño ajustado por riesgo.

En los resultados obtenidos, los umbrales óptimos encontrados fueron:

```
Entrada=1.76, Salida=0.15
```

Reglas de trading

La estrategia sigue una lógica de reversión a la media:

- Se toma una **posición larga en el spread** cuando:

$$z_t < -z_{entry}$$

- Se toma una **posición corta en el spread** cuando:

$$z_t > z_{entry}$$

- Se cierra la posición cuando:

$$|z_t| < z_{exit}$$

Estas reglas permiten capturar movimientos de convergencia hacia el equilibrio, evitando operar en zonas cercanas a la media donde la señal es débil.

Position sizing basado en el vector de pesos

Las posiciones se construyen utilizando el vector de cointegración dinámico β_t, el cual define la exposición relativa a cada activo. Esto garantiza que el portafolio sea aproximadamente neutral al mercado, ya que las posiciones largas y cortas se compensan entre sí.

En la práctica, cada activo se pondera proporcionalmente a su peso en β_t, ajustando el signo de acuerdo con la señal (long o short spread).

Tratamiento de costos de transacción y financiamiento

La estrategia incorpora costos de transacción de manera explícita, aplicando una comisión por operación equivalente al 0.125% del capital transaccionado. Estos costos se aplican únicamente cuando se produce un cambio en la posición, es decir, al abrir o cerrar operaciones.

Adicionalmente, aunque no se modela explícitamente en todos los casos, la estrategia considera implícitamente costos de financiamiento asociados a posiciones cortas, lo cual es consistente con la práctica real en estrategias de arbitraje estadístico.

El impacto de estos costos se refleja en los retornos netos de la estrategia, los cuales se calculan como:

$$\text{Retorno neto} = \text{Retorno bruto} - \text{Costos de transacción}$$

Para validar esta sección, es recomendable incluir:

- La distribución de señales generadas
- El retorno acumulado neto

Tal como fue reportado en los resultados obtenidos.

La estrategia implementada combina un enfoque estadístico riguroso con una lógica de trading disciplinada, basada en la identificación de desviaciones temporales respecto al equilibrio de largo plazo. El uso de filtros de Kalman permite adaptar el modelo en tiempo real, mientras que la optimización de umbrales asegura que las decisiones de trading estén respaldadas por evidencia empírica.

6. Results and Performance Analysis

En esta sección se evalúa de manera integral el desempeño de la estrategia propuesta, considerando tanto métricas de rentabilidad como de riesgo, así como su comportamiento fuera de muestra. El análisis se centra en determinar si la combinación de cointegración multivariada, filtros de Kalman y reglas de trading genera resultados consistentes y económicamente significativos.

Evolución del capital (Equity Curve)

El desempeño de la estrategia se analiza inicialmente mediante la **curva de capital acumulado**, construida a partir de los retornos netos después de costos:

$$\text{Equity}_t = \prod_{i=1}^{t} (1 + r_i^{net})$$

Esta curva permite visualizar de forma clara:

- La tendencia general de crecimiento del portafolio
- Periodos de pérdidas (drawdowns)
- Estabilidad o volatilidad del desempeño

En los resultados obtenidos, la estrategia muestra una trayectoria creciente en el periodo fuera de muestra, lo cual sugiere que el modelo no está completamente sobreajustado y mantiene capacidad predictiva en datos no vistos.

Métricas de desempeño

Para cuantificar el rendimiento, se calcularon diversas métricas estándar en finanzas cuantitativas.

Sharpe Ratio

El Sharpe Ratio mide el retorno ajustado por la volatilidad total:

$$\text{Sharpe} = \frac{\mathbb{E}[r]}{\sigma(r)}$$

En este caso, el Sharpe anualizado obtenido es aproximadamente:

- **Sharpe ≈ 1.91**

Este valor indica una estrategia con buen desempeño ajustado por riesgo, ya que valores superiores a 1 son considerados sólidos, mientras que valores cercanos a 2 reflejan estrategias altamente eficientes.

Maximum Drawdown

El drawdown máximo mide la peor pérdida relativa desde un pico de capital:

$$\text{Drawdown}_t = \frac{\text{Equity}_t - \max(\text{Equity})}{\max(\text{Equity})}$$

El resultado obtenido es:

- **Max Drawdown ≈ -13.4%**

Este nivel de pérdida es moderado y consistente con estrategias de reversión a la media, donde las posiciones pueden mantenerse en contra del movimiento de corto plazo antes de revertir.

- **Sortino ≈ 1.53**

Este resultado indica que la estrategia mantiene un buen control sobre las pérdidas, aunque ligeramente inferior al Sharpe Ratio (≈ 1.91). Esta diferencia sugiere la presencia de cierta volatilidad negativa, lo cual es consistente con estrategias de reversión a la media, donde temporalmente pueden acumularse pérdidas antes de la convergencia del spread hacia su equilibrio.

En términos prácticos, este valor confirma que la estrategia no solo es rentable, sino que además logra gestionar razonablemente bien el riesgo a la baja, lo cual es fundamental para su implementación en entornos reales.

- **Calmar Ratio ≈ 5.45**

El **Calmar Ratio** mide la relación entre el retorno anual de la estrategia y su máxima pérdida histórica. A diferencia del Sharpe o Sortino, este ratio se enfoca en el riesgo extremo, capturando la severidad de las caídas del portafolio.

Este resultado es particularmente sólido, ya que indica que el retorno generado es más de cinco veces superior al peor escenario de pérdida observado. En términos de gestión de riesgo, esto implica que la estrategia presenta una alta eficiencia en la relación entre rentabilidad y exposición a caídas extremas.

El alto valor del Calmar Ratio refuerza la robustez del enfoque, mostrando que, a pesar de los periodos de drawdown inherentes a estrategias de mean-reversion, el sistema logra recuperarse rápidamente y generar valor de manera consistente.

Estadísticas de trading

El análisis de las señales generadas muestra que:

- La mayoría del tiempo la estrategia permanece sin posición (neutral)
- Las operaciones se activan únicamente en eventos extremos del z-score

Esto indica que la estrategia es:

- Altamente selectiva
- Basada en oportunidades de desalineación significativa

```
Número total de trades: 46
Long trades: 38
Short trades: 50
Proporción Long: 0.43
Proporción Short: 0.57
Frecuencia de operación: 0.0562
```

7. Conclusions

El desarrollo de esta estrategia de statistical arbitrage basada en cointegración multivariada y filtros de Kalman permitió evaluar la viabilidad de explotar relaciones de equilibrio de largo plazo entre múltiples activos financieros mediante un enfoque dinámico y adaptativo.

En términos generales, los resultados muestran que, aunque es posible construir portafolios con alta correlación entre activos y obtener combinaciones lineales mediante el test de Johansen, la evidencia de cointegración robusta no fue consistente en todos los casos analizados. En particular, la validación del spread mediante la prueba ADF arrojó valores de p elevados en varios portafolios, lo que indica que la estacionariedad —condición fundamental para la estrategia— no se cumple de manera sólida. Esto sugiere que, aun cuando los activos presentan dinámicas similares, no necesariamente comparten una relación de equilibrio estable en el tiempo.

A pesar de esta limitación, la implementación de los filtros de Kalman demostró ser efectiva desde el punto de vista metodológico. El sistema fue capaz de estimar dinámicamente los pesos del portafolio y generar un spread que evoluciona de forma estable, mientras que el segundo filtro permitió construir un z-score en tiempo real sin introducir sesgo de anticipación. Las gráficas del spread y del z-score evidencian que el modelo se comporta de manera estable y no presenta problemas de divergencia, lo cual confirma la correcta especificación de los parámetros y la estabilidad numérica del sistema.

En cuanto al desempeño de la estrategia, los resultados indican que se pueden generar retornos positivos incluso después de considerar costos de transacción, aunque estos resultados deben interpretarse con cautela. La frecuencia relativamente baja de señales y la falta de estacionariedad fuerte en el spread sugieren que los beneficios observados pueden no ser sostenibles en el largo plazo o en condiciones de mercado distintas. Para reforzar este punto en el reporte, es recomendable incluir explícitamente el retorno neto acumulado obtenido en el backtest.

El análisis fuera de muestra también sugiere que la persistencia de la cointegración es limitada. Esto es consistente con la literatura financiera, donde las relaciones de cointegración pueden romperse debido a cambios estructurales en el mercado, eventos macroeconómicos o transformaciones en los modelos de negocio de las empresas. En este contexto, el uso de filtros de Kalman representa una ventaja importante, ya que permite adaptar el modelo a nuevas condiciones, aunque no puede compensar completamente la ausencia de una relación de equilibrio subyacente.

Finalmente, existen diversas oportunidades de mejora que podrían fortalecer significativamente la estrategia. En primer lugar, la selección de activos podría optimizarse utilizando un universo más amplio y aplicando criterios más estrictos de cointegración, incluyendo pruebas adicionales

o enfoques basados en machine learning. En segundo lugar, el modelo podría extenderse incorporando un VECM completo en la generación de señales, en lugar de utilizar únicamente el spread como aproximación del término de corrección de error. Asimismo, sería recomendable incluir una modelación más detallada de costos de financiamiento y restricciones de liquidez, así como explorar técnicas de optimización de portafolio más avanzadas.

En conclusión, la estrategia desarrollada demuestra que el enfoque de cointegración multivariada combinado con filtros de Kalman es conceptualmente sólido y metodológicamente robusto. Sin embargo, su viabilidad práctica depende críticamente de la correcta identificación de relaciones de cointegración estables, lo cual representa el principal desafío en la implementación real de este tipo de estrategias.